도심 이면 교차로에서 차로별 좌표계 변환에 의한 차량 속도 추정 기반 사고 위험 상황 분류 모델

Model for classifying accident risk situations based on vehicle speed estimation through lane-specific coordinate transformation at urban backstreet intersections

김승현, 강한빈, 강종규, 배창석

(34520) 대전광역시 동구 대학로 62, 대전대학교 정보통신공학과

한국차세대컴퓨팅학회
Korean Institute of Next Generation Computing

연구 배경

현대 사회는 다양한 교통수단으로 편리함을 추구하고 있다. 그러나 이러한 교통수단의 치명적인 문제점은 교통사고로 인해 매년 30만 명에 가까운 사람이 다치고 3천 명 규모의 사람이 목숨을 잃고 있다는 사실이다.

- 경찰에서 조사, 처리한 교통사고 정보에 따르면 2023년 교통사고 건수는 196,836건이고, 이 중 교차로에서 발생한 사건 수가 95,354건으로 약 48.44%로 절반을 차지했다.

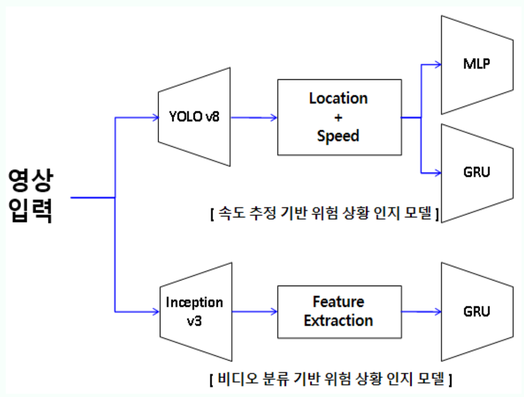
- 교통사고를 예방하기 위한 인공지능과 빅데이터를 활용한 사고 예측 및 예방 기술이 주목받고 있으며, 스마트 교차로 시스템, 운전자 보조 시스템 등 다양한 방법들이 연구되고 있다. 특히 운전자 보조 시스템의 한계를 인지함에 따라 교통 인프라를 활용하여 이를 보조하는 해결 방안을 찾고 있다.

연구의 필요성

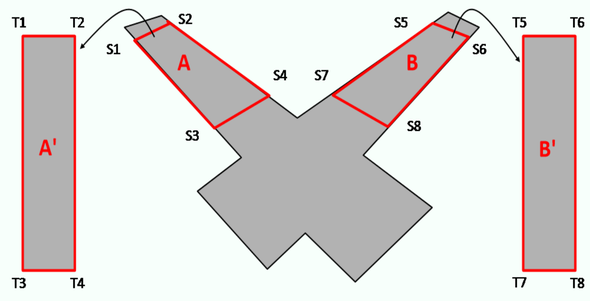
이러한 현재 상황에 주목하여 교차로에서의 교통사고 문제를 경감하는 방안을 제시하고자 한다. 본 연구를 기반으로 교통 인프라 서비스를 개발하면 시야 제한과 운전자의 운전 미숙으로 인해 발생하는 사고를 예방하여 사고율 및 사망률을 줄이는데 기여할 수 있으며, 2차 사고를 예방하거나, 교통 흐름을 원만하게 하는 등 활용 가능성이 무궁무진하다.

연구 방법

현재 교차로의 내 상황을 분석하는 시스템과 지능형 영상 분석 기술을 살펴보고, 이를 활용하여 도심 이면 교차로 내 위험 상황 인지 모델을 제안한다.



(그림1) 위험 상황 인지 모델 제안 구조도



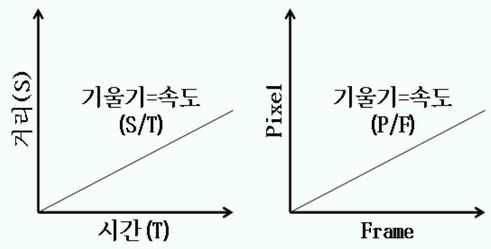
(그림2) 차로별 독립적 BEV 변환

본 연구에서는 교차로 환경을 가정하여 영상 데이터 셋을 구성하고, 속도 추정 기반 위험 상황 인지 모델을 제안한다. 성능 평가를 위해 비교군으로는 비디오 분류 기반 위험 상황 인지 모델을 둔다.

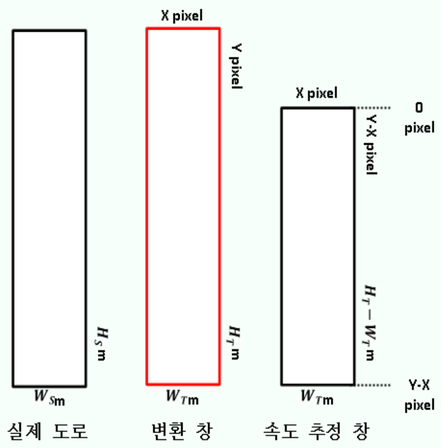
(그림1)은 본 연구에서 사용하는 3가지 상황 인지 모델의 구조를 (그림 2)에서 보여주고 있다. 먼저, 제안하는 속도 추정 기반 위험 상황 인지 모델은 YOLO v8을 통해 객체의 위치와 속도를 추정한다. 이후 추정된 정보를 통해 MLP와 GRU, 두 가지 인공지능 분류기 모델을 사용하여 위험도를 분류한다. 비교군인 비디오 분류 기반 위험 상황 인지 모델은 비디오 분류에서 흔히 볼 수 있는 CNN+RNN의 구조를 활용하여 위험도를 분류한다.

단일 카메라를 통해 영상을 받고, 이를 두 가지 접근 방법 (속도 추정 기반, 비디오 분류 기반)의 입력값으로 넣는다. 이후 출력되는 특징을 활용하여 인공지능 분류기 모델에 입력값으로 넣어 교차로의 세 가지 상황 (안전, 주의, 위험) 중 하나로 분류하여 위험 상황을 인지할 수 있도록 한다.

동적 객체의 인지 및 추적을 위해 단일 카메라로 들어오는 영상을 YOLO v8에 입력한다. 이때, 단일 카메라를 통해 차량의 위치와 속도를 추정하기 위해서는 2차원 영상 좌표계로 표현된 객체의 특징을 3차원 좌표계로 변환하여 표현할 수 있어야 한다. 또한 카메라는 거리가 멀수록 객체의 크기와 움직임은 작고, 가까울수록 큰 원근 왜곡 현상이 발생한다. 이러한 문제를 해결하기 위해 (그림2)와 같이 Bird's Eye View (BEV) 변환을 활용한다.



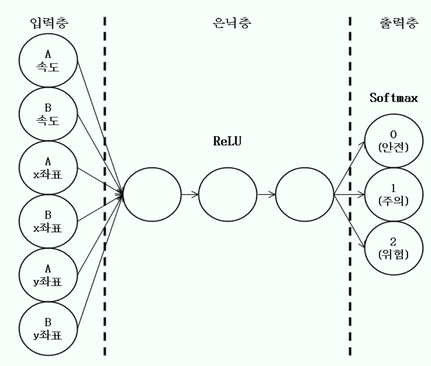
(그림 3) S-T 그래프, P-F 그래프

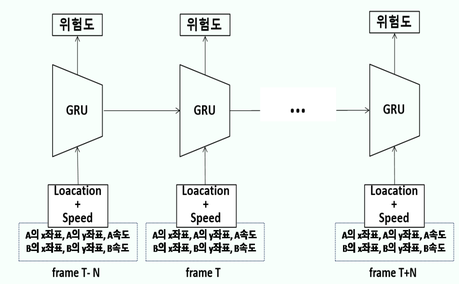


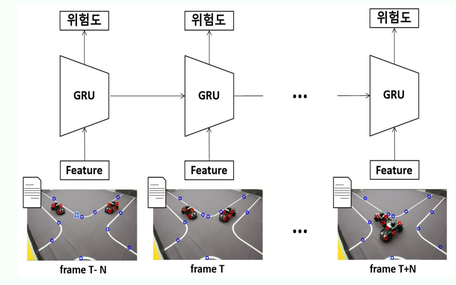
(그림 4) 실제 도로, 변환 창, 속도 추정 창 크기

위에서 설명한 BEV 변환을 통해 얻은 동적 객체의 위치 (좌표) 값을 활용하여 속도를 추정할 수 있다. 기본적으로 물체의 속도를 구하기 위해서는 물체가 이동한 거리와 그 거리만큼 이동하는 데 걸린 시간이 필요하다.

물리의 역학에서는 속도, 가속도를 다루는 과정 중 거리-시간 그래프와 속도-시간 그래프를 활용하여 기본적인 동역학을 이해한다. 이 과정에서 거리-시간 그래프의 기울기는 물체의 속도를 나타낸다. 이 개념을 영상분석에 적용하면, (그림 4)에서 보여주는 바와 같이 거리는 화소 (Pixel), 시간은 프레임 (Frame)으로 고려할 때, 화소/프레임 (Pixel/Frame) 단위로 영상 속 물체의 속도를 추정할 수 있다.







- MLP 분류기 모델 구조

본 연구에서 제안하는 MLP 구조는 보여주는 바와 같이 1개의 입력층, 3개의 은닉층, 1개의 출력층을 가지고, 입력층 노드 6개, 출력층 노드 3개로 고정한다. 입력층 노드는 A의 속도와 위치, B의 속도와 위치를 넣고, 위치는 x와 y로 나누어 총 6개의 노드를 가진다. 은닉층의 노드 수는 학습을 통해 찾아내고, 활성화 함수는 ReLU를 활용한다. 출력층의 클래스는 3가지(안전, 주의, 위험) 클래스로 다중 분류 문제이기 때문에 출력층의 활성화 함수는 Softmax를 사용한다.

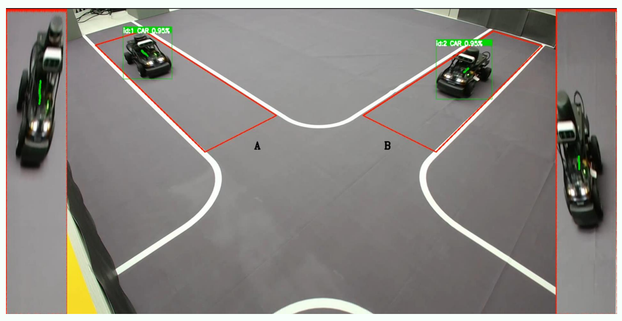
- GRU 분류기 모델 구조

GRU는 교차로에 진입한 객체의 위치와 속도를 프레임 단위로 CSV 파일 형식으로 저장하고, 이 데이터를 통해서 학습한다. 이때 영상의 프레임 길이는 차량의 속도나 상황에 따라서 다를 수 있어 최대 길이의 영상 프레임을 측정하고, 이에 맞게 Padding 과 Masking을 통해서 데이터 길이에 상관없이 학습한다.

- Video Classification 모델

특징추출 모델인 Inception-v3 모델을 통해 특징을 시계열 데이터로 추출한 뒤, 영상이 재생되면서 변하는 특징의 흐름을 GRU 모델로 학습시킨다고 볼 수 있다. 이를 통해 움직이지 않는 정적인 영상 환경에서 동적인 객체의 특징을 학습하여 추출할 수 있다.

연구 결과

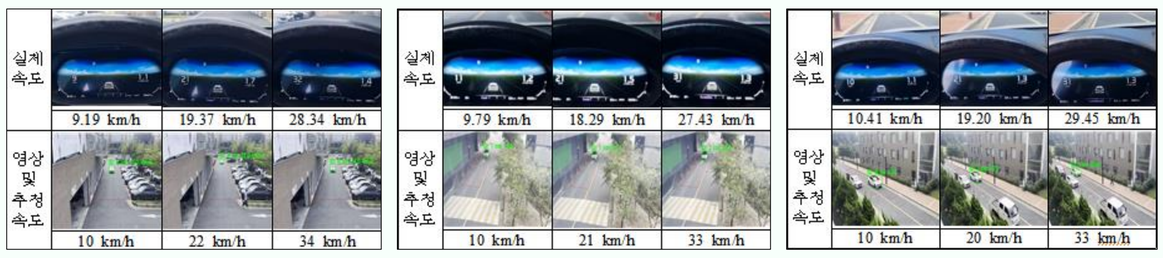


(그림5) 원본 영상과 변환 영상

	YOLO+MLP	YOLO+GRU	Video Classification
Accuracy	0.89	0.64	0.86
F1-score	0.88	0.62	0.86
Recall	0.88	0.59	0.86
Precision	0.89	0.62	0.86
추론시간	5 ms	10 ms	1120 ms

(표1) 세 가지 모델에 대한 성능 지표

실험 결과 분석을 위해 각 모델의 테스트 데이터에 대한 성능 지표를 (표 1)에서 보여주고 있다. YOLO+MLP는 YOLO+GRU에 비해 Accuracy가 약 35% 뛰어나며, Video Classification에 비해 추론 시간이 약 224배 빠른 결과를 보인다



(그림6) 실세계 도로 영상 구축 및 실험 결과 분석

본 연구에서 제안하는 모델은 차량의 속도를 기반으로 교차로의 위험 상황을 "안전", "주의", 그리고 "위험"의 3 가지로 구분한다. 따라서 속도 추정의 정확성이 보장된다면 이후 위험 상황의 판단은 3.1.3절과 3.1.4절에서 논의한 바와 같이 MLP 또는 GRU를 통해 이루어진다. 따라서 제안하는 모델이 실제 도로 환경에서도 우수한 성능을 보일 것으로 기대할 수 있다.

연구 의의

이후 연구에서는 실험 결과를 토대로 영상 데이터를 추가적으로 확보하고, 위험도 분류 기준에 위치와 속도 이외의 특징을 활용하여 위험 상황 인지 모델을 만들고자 한다. 특히, Nvidia의 AI City Challenge Dataset 중 교통 안전과 관련된 데이터 등 관련 공개 데이터에 대해 제안하는 모델을 확장하여 적용하고자 한다. 또한, 실시간으로 교차로 내 위험 상황을 인지하고 판단하여 신호 및 차량을 제어할 수 있는 교차로 시스템을 구축하는 연구를 지속적으로 진행하고자 한다.